Imersão em IA

Deploy de Modelos em Produção

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **Shadow Deploy:** O Observador Silencioso.
- **Canary Release:** Redução Segura de Riscos.
- **A/B Testing:** Tomada de Decisão com Dados.
- **Orquestração Distribuída:** O Poder do Ray Serve.
- Lab 07 (Recap) e Lab 08 (Ray Serve).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 07 - War Room Tracking (Recuperação)

Missão: Finalizar a Rastreabilidade

- Registro de métricas de performance (Acurácia/Loss).
- Log de hiperparâmetros e linhagem do modelo.
- Garantia da **Auditoria** antes do Deploy.
- **Check:** Modelo registrado e pronto para subir.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Por que o Deploy de IA é Crítico?

Código é Estático, Modelos são Vivos

- Modelos são "caixas pretas" até o tráfego real.
- Dependência tripla: Código + Dados + Ambiente.
- Erros de lógica ≠ Erros de performance do modelo.
- **Risco:** Impacto imediato no cliente final (CAIXA).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Estratégia 1 – Shadow Deploy

O "Espelho" do Modelo Antigo

- **O que é:** Rodar modelo novo em paralelo ao atual.
- **Execução:** Saída do novo modelo é apenas logada.
- **Vantagem:** Risco zero para o cliente.
- **Desafio:** Custo de infraestrutura duplicado.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Estratégia 2 – Canary Release

O "Passarinho" na Mina de Carvão

- **O que é:** Liberação progressiva por tráfego (10%).
- **Execução:** Se métricas OK, escala gradualmente.
- **Vantagem:** "Kill Switch" rápido em caso de falha.
- **Cenário:** Ideal para novos modelos de crédito/risco.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Estratégia 3 – A/B Testing

A Batalha das Hipóteses

- **O que é:** Tráfego dividido (50/50 ou similar).
- **Execução:** Comparação direta de conversão/valor.
- **Vantagem:** Validar métricas de negócio, não só ML.
- **Meta:** Tomar decisões baseadas em evidências.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ecossistema de Model Serving

Da API Simples à Plataforma Robusta

- **FastAPI/Flask:** Ótimos para protótipos rápidos.
- **Ray Serve:** Orquestração distribuída nativa (OpenAI).
- **Kserve:** O padrão ouro para Kubernetes corporativo.
- **Meta:** Migrar da Infraestrutura para a Plataforma.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Monitoramento Pós-Deploy

Vigilância Constante na Produção

- **Drift Detection:** O dado mudou ou a IA "cansou"?
- **Feedback Loops:** Capturar o "chão de fábrica" do erro.
- **Retreinamento:** Fechando o ciclo de CI/CD/CT.
- **Regra:** Produção não é o fim, é o laboratório real.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 08 – A Orquestra da IA (Ray Serve)

Missão: Abstrair a Infraestrutura

- Escala horizontal automática via código (Ray Actors).
- Roteamento inteligente para Canary Release.
- **Hot-update:** Atualização sem queda de serviço.
- **Check:** Ver o cluster Ray balanceando a carga.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Wrap-up: MLOps

O Próximo Nível da Engenharia

- Reprodutibilidade é o alicerce do Compliance.
- Rastreabilidade é a segurança do Engenheiro.
- Escala é a necessidade do Negócio.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS